TÀI LIỆU ĐẶC TẢ YÊU CÂU PHẦN MỀM

HỆ THỐNG HỎI ĐÁP VÀ TRA CỨU VĂN BẢN QUY PHẠM PHÁP LUẬT VIỆT NAM

Thông tin Quản lý Tài liệu	Chi tiết Đặc tả
Tên Hệ thống	Hệ thống Hỏi đáp Văn bản Quy phạm Pháp luật
Mã Tài liệu	SRS-LEGAL-RAG-001
Phiên bản	2.0
Ngày Ban hành	18/10/2026
Tiêu chuẩn Tham chiếu	ISO/IEC/IEEE 29148:2018
Mô hình Triển khai	Mô hình Lai: Cloud Free-Tier Offload (Vector DB/PostgreSQL/Backend) kết hợp Local LLM (Ollama)
Trạng thái Tài liệu	Chính thức

Bảng Lịch sử Phiên bản

Phiên bản	Ngày cập nhật	Mô tả Thay đổi	T
1.0	14/10/2026	Khởi tạo đặc tả yêu câu phân mềm cho hệ thống RAG Pháp luật.	Đ
2.0	16/10/2026	Tinh gọn thuật ngữ, cập nhật cấu hình phần cứng tối ưu tài	B

Phiên bản	Ngày cập nhật	Mô tả Thay đổi	T
		nguyên và chuẩn hóa toàn bộ nội dung đặc tả.	

1. GIỚI THIỆU

1.1. Mục đích Tài liệu

Tài liệu này quy định chi tiết các yêu cầu chức năng, yêu cầu phi chức năng, cấu trúc dữ liệu, giao diện tích hợp và tiêu chí nghiệm thu đối với Hệ thống Hỏi đáp Văn bản Quy phạm Pháp luật Việt Nam dựa trên kiến trúc RAG sử dụng các mô hình trí tuệ nhân tạo tự vận hành. Tài liệu là cơ sở kỹ thuật thống nhất cho đội ngũ phát triển và kiểm thử trong suốt quá trình thiết kế, xây dựng, tích hợp và vận hành hệ thống.

1.2. Phạm vi Hệ thống

Hệ thống tiếp nhận câu hỏi bằng ngôn ngữ tự nhiên tiếng Việt, tự động truy xuất các điều khoản pháp lý liên quan từ kho dữ liệu Văn bản Quy phạm Pháp luật, và tổng hợp câu trả lời chính xác kèm trích dẫn nguyên văn căn cứ pháp lý gồm Điểm, Khoản, Điều, Số hiệu văn bản. Toàn bộ quá trình mã hóa vector, tìm kiếm lai, tái xếp hạng và sinh ngôn ngữ được thực thi nội bộ hoặc kết hợp lưu trữ đám mây theo cấu hình triển khai.

Hạng mục Phạm vi	Trong Phạm vi Triển khai	Định hướng Mở rộng
Định dạng Văn bản Nguồn	Văn bản điện tử có lớp văn bản chuẩn gồm .docx, .pdf, .html, .txt ban hành theo thể thức Nghị định 30/2020/NĐ-CP.	Tài liệu PDF quét độ phân giải thấp, bị con dấu đỏ hoặc chữ ký đè lên văn bản đòi hỏi pipeline OCR phức tạp.
Câu trúc Bóc tách	Phân tách tự động theo câu trúc phân cấp chuẩn: Phần ->	Nhận diện sơ đồ hình ảnh đính kèm, bản vẽ kỹ thuật hoặc

Hạng mục Phạm vi	Trong Phạm vi Triển khai	Định hướng Mở rộng
	Chương -> Mục -> Điều -> Khoản -> Điểm; bảo toàn bảng biểu dạng Markdown.	công thức toán học dạng ảnh bitmap.
Cơ chế Truy xuất	Hybrid Search kết hợp Dense Vector và Sparse Vector cùng bộ lọc Metadata và mô hình Cross-Encoder Reranker.	Truy vết đồ thị tri thức đa chặng không giới hạn qua hàng chục văn bản dẫn chiếu nối tiếp.
Kiểm soát Ảo giác	Ép buộc trích dẫn nguyên văn từng Điều, Khoản và tự động từ chối trả lời khi điểm tin cậy dưới ngưỡng chuẩn.	Tư vấn chiến lược tố tụng hoặc đưa ra phán quyết pháp lý thay thế chuyên gia luật sư.
Hạ tầng Vận hành	Đóng gói đồng bộ qua Docker Compose bao gồm Vector DB, Embedding, Reranker, LLM Serving, API và UI.	Hệ thống điều phối đa cụm máy chủ hoặc huấn luyện lại mô hình nền tảng từ đầu.

1.3. Định nghĩa, Thuật ngữ và Từ viết tắt

Thuật ngữ	Giải thích Chi tiết
VBQPPL	Văn bản Quy phạm Pháp luật bao gồm Hiến pháp, Bộ luật, Luật, Pháp lệnh, Nghị quyết, Nghị định, Quyết định, Thông tư.
RAG	Kiến trúc kết hợp truy xuất thông tin từ cơ sở tri thức chuẩn xác trước khi đưa vào mô hình ngôn ngữ lớn để sinh câu trả lời.

Thuật ngữ	Giải thích Chi tiết
Câu trúc Phân cấp Pháp lý	Hệ thông tô chức nội dung chặt chẽ của văn bản luật Việt Nam theo thứ tự: Phần -> Chương -> Mục -> Tiểu mục -> Điều -> Khoản -> Điểm.
Breadcrumb	Chuôi định danh đường dân phân cấp được gắn trực tiếp vào đầu mỗi chunk để bảo toàn ngữ cảnh khi tách nhỏ.
Hybrid Search	Kỹ thuật tìm kiếm kết hợp song song giữa tìm kiếm ngữ nghĩa và tìm kiếm từ khóa chính xác.
RRF	Thuật toán hợp nhất thứ hạng giúp tông hợp kết quả từ nhiều luồng truy xuất có thang điểm khác nhau.
Cross-Encoder Reranker	Mô hình mạng nơ-ron châm điêm mức độ liên quan trực tiếp giữa cặp câu hỏi và đoạn văn bản bằng cơ chế Self-Attention.
Cơ chế Từ chối	Cơ chế an toàn buộc hệ thống từ chối đưa ra kết luận khi dữ liệu truy xuất không đủ độ tin cậy, nhằm triệt tiêu hiện tượng ảo giác.
TTFT	Thời gian trễ tính từ lúc hệ thống nhận truy vấn đến khi trả về token đầu tiên của câu trả lời.

1.4. Tài liệu Tham chiếu

- ISO/IEC/IEEE 29148:2018: Tiêu chuẩn quốc tế về quy trình kỹ thuật và đặc tả yêu cầu phần mềm.

- Luật Ban hành văn bản quy phạm pháp luật số 80/2015/QH13 và Luật sửa đổi, bổ sung số 63/2020/QH14.
- Nghị định số 30/2020/NĐ-CP về công tác văn thư, thể thức và kỹ thuật trình bày văn bản hành chính.

2. MÔ TẢ TÔNG QUAN HỆ THÔNG

2.1. Đặc thù của Văn bản Pháp luật Việt Nam và Bài toán Kỹ thuật

- Tính toàn vẹn phân cấp: Quy định pháp lý được chia nhỏ thành Điều, Khoản và các Điểm a, b, c. Việc cắt văn bản theo độ dài ký tự cố định sẽ làm tách rời các Điểm khỏi câu dẫn ở đầu Khoản hoặc đầu Điều, gây sai lệch ngữ nghĩa.
- Độ nhạy tuyệt đối với số hiệu và thuật ngữ chuyên ngành: Hệ thống phải xử lý đồng thời câu hỏi ngôn ngữ tự nhiên và truy vấn đích danh số hiệu văn bản hoặc con số định lượng.
- Hiện tượng dẫn chiếu chéo: Các điều khoản thường tham chiếu sang điều khoản khác trong cùng văn bản hoặc văn bản sửa đổi, bổ sung. Hệ thống cần nhận diện được sự thiếu hụt thông tin khi có dẫn chiếu.
- Tính hiệu lực theo thời gian: Hệ thống truy xuất phải phân biệt rõ trạng thái hiệu lực để ưu tiên các văn bản đang còn hiệu lực.

2.2. Kiến trúc Tổng thể Hệ thống

Hệ thống gồm hai luồng xử lý tách biệt:

- Luồng Xử lý và Lập chỉ mục Dữ liệu: Tiếp nhận tệp văn bản gốc -> Chuẩn hóa bảng mã Unicode NFC và lọc nhiễu hành chính -> Phân tích cấu trúc phân cấp và bảo toàn bảng biểu -> Gắn nhãn Breadcrumb -> Mã hóa kép qua mô hình BAAI/bge-m3 -> Lưu trữ vector và trường Metadata vào cơ sở dữ liệu.
- Luồng Truy vấn và Sinh câu trả lời Thời gian thực: Tiếp nhận câu hỏi -> Bóc tách thực thể pháp lý tạo bộ lọc Metadata -> Thực thi Hybrid Search -> Hợp nhất kết quả bằng thuật toán RRF lấy Top-25 ứng viên -> Chấm điểm tương quan sâu bằng

mô hình BAAI/bge-reranker-v2-m3 lấy Top-5 ứng viên -> Kiểm tra ngưỡng tin cậy -> Đưa ngữ cảnh vào mô hình Qwen2.5-Instruct -> Trả kết quả dạng Streaming kèm danh sách trích dẫn nguồn đối chiếu.

2.3. Phân loại Người dùng

Nhóm Người dùng	Vai trò và Mục đích Sử dụng	Yêu cầu Kỹ thuật Trọng tâm
Người dùng Tra cứu	Đặt câu hỏi pháp lý bằng ngôn ngữ tự nhiên hoặc tra cứu điều khoản cụ thể; đối chiếu câu trả lời với trích đoạn văn bản gốc.	Giao diện trực quan, phản hồi Streaming, hiển thị rõ thẻ trích dẫn để kiểm chứng.
Quản trị viên Tri thức	Tải lên văn bản pháp luật mới, cập nhật trạng thái hiệu lực của văn bản, kiểm tra danh mục chỉ mục.	Công cụ nạp dữ liệu hàng loạt, cơ chế chống trùng lặp và quản lý Metadata.
Kỹ sư Vận hành Hệ thông	Triên khai, giám sát tài nguyên phần cứng, theo dõi độ trễ truy vấn, tinh chỉnh ngưỡng điểm Reranker và kiểm định chất lượng.	Triên khai một chạm qua Docker Compose, có endpoint kiểm tra sức khỏe dịch vụ và log truy vết chi tiết.

2.4. Môi trường Vận hành và Cấu hình Phần cứng

Thành phân Hệ thống	Cấu hình Tiêu chuẩn	Câu hình Tôi ưu Tài nguyên	Câu hình Lai Tôi ưu Đám mây
Tài nguyên Tính toán	1-2 GPU NVIDIA 24GB-48GB VRAM	1 GPU NVIDIA 4GB VRAM hoặc CPU đa nhân	CPU/GPU cá nhân chạy Local LLM; hạ

Thành phần Hệ thống	Cấu hình Tiêu chuẩn	Câu hình Tối ưu Tài nguyên	Câu hình Lai Tối ưu Đám mây
	(RTX 3090, RTX 4090, A100)		tầng phụ trợ đây lên Cloud
CPU và RAM Máy chủ	Tối thiểu 16 vCPU, 32GB RAM, 200GB NVMe SSD	Tối thiểu 8 vCPU, 16GB RAM, 100GB NVMe SSD	Tối thiểu 4 vCPU, 8GB RAM local; Cloud Free-Tier điều phối
Mô hình Ngôn ngữ Lớn	Qwen2.5-14B-Instruct AWQ hoặc FP16	Qwen2.5-3B-Instruct GGUF hoặc Qwen2.5-7B-Instruct GGUF	Ollama chạy cục bộ mô hình Qwen2.5-3B/7B trên CPU/GPU local
Engine Phục vụ LLM	vLLM hỗ trợ PagedAttention và Continuous Batching	Ollama hoặc llama.cpp server	Ollama Local Server (localhost:11434)
Mô hình Embedding & Reranker	BAAI/bge-m3 & BAAI/bge-reranker-v2-m3 FP16	BAAI/bge-m3 & BAAI/bge-reranker-v2-m3 ONNX trên CPU	Mô hình chạy trên Hugging Face Inference Endpoints hoặc Colab CPU/GPU
Cơ sở Dữ liệu Vector	Milvus Standalone v2.4 qua Docker Compose	Qdrant hoặc Milvus Standalone qua Docker Compose	Qdrant Cloud Free-Tier hoặc Zilliz Cloud Free-Tier
Cơ sở Dữ liệu Quan hệ	PostgreSQL local qua Docker Compose	PostgreSQL local qua Docker Compose	Neon.tech Free-Tier hoặc Supabase Free-Tier

Thành phần Hệ thống	Cấu hình Tiêu chuẩn	Câu hình Tối ưu Tài nguyên	Câu hình Lai Tối ưu Đám mây
Backend và Giao diện	FastAPI Async REST SSE và Chainlit UI	FastAPI Async REST SSE và Gradio/Chainlit UI	FastAPI Backend triển khai Render/Koyeb Free-Tier, UI Chainlit/Streamlit

2.5. Giả định và Ràng buộc Kỹ thuật

- Ràng buộc Bảo mật: Mô hình ngôn ngữ lớn vận hành hoàn toàn cục bộ, không gửi nội dung truy vấn nhạy cảm của người dùng ra các dịch vụ LLM bên ngoài.
- Chuẩn Mã hóa Tiếng Việt: Tất cả văn bản đầu vào được chuẩn hóa về bảng mã Unicode dựng sẵn UTF-8 chuẩn NFC trước khi đưa vào bộ phân tích cú pháp.
- Môi trường Hệ điều hành: Máy chủ hoặc máy trạm cài đặt sẵn Docker Engine, Docker Compose v2 và trình điều khiển GPU tương thích CUDA 12.1 trở lên.

3. YÊU CẦU CHỨC NĂNG CHI TIẾT

3.1. Phân hệ 1: Thu thập, Tiền xử lý và Phân mảnh Văn bản theo Cấu trúc

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu cầu Chức năng
FR-ING-01	Bắt buộc	Trích xuất Đa định dạng và Bảo toàn Bảng biểu: Hỗ trợ đọc tệp .docx, .pdf và .html thông qua thư viện IBM Docling kết hợp PyMuPDF và python-docx. Các bảng biểu

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu câu Chức năng
		phải được chuyên đôi sang định dạng bảng Markdown chuẩn, giữ nguyên liên kết dòng và cột.
FR-ING-02	Bắt buộc	Chuân hóa Văn bản và Lọc Nhiễu Hành chính: Tự động chuẩn hóa toàn bộ chuỗi ký tự về Unicode NFC; loại bỏ số trang, tiêu đề đầu trang, chân trang lặp lại, khối chữ ký, nơi nhận và dấu phân cách trang trước khi phân tích cấu trúc.
FR-ING-03	Bắt buộc	Phân tích Câu trúc Phân câp bằng Máy trạng thái: Không cắt văn bản theo số lượng ký tự cố định. Bộ phân tích phải nhận diện cây phân cấp Phần -> Chương -> Mục -> Tiểu mục -> Điều -> Khoản -> Điểm thông qua bộ quy tắc biểu thức chính quy chuyên biệt.
FR-ING-04	Bắt buộc	Quy tăc Cắt Chunk theo Điều, Khoản và Bảo toàn Câu dẫn: Đơn vị cơ sở của một chunk là một Điều. Trường hợp một Điều vượt quá 1.024 tokens, hệ thống tự động tách nhỏ

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu câu Chức năng
		xuông cấp Khoản và bắt buộc sao chép tiêu đề Điều cùng câu dẫn mở đầu của Điều ghép vào phía trước mỗi Khoản.
FR-ING-05	Bắt buộc	Tiêm Ngữ cảnh Phân cấp: Trước khi đưa văn bản vào mô hình Embedding, mỗi chunk phải được gắn tiêu đề định danh nguồn gốc ở đầu văn bản theo mẫu: [Văn bản: {doc_type} {doc_number} - {doc_title}] [Chương {chapter_id}] [Mục {section_id}] [Điều {article_id}: {article_title}].
FR-ING-06	Quan trọng	Nhận diện Dẫn chiếu Chéo: Tự động quét và trích xuất danh sách các Điều, Khoản hoặc số hiệu văn bản khác được viện dẫn bên trong nội dung chunk, lưu vào trường mảng metadata referenced_provisions.

Quy tắc Biểu thức Chính quy Nhận diện Cấu trúc Pháp lý

REGEX_PART = r"^(PHÂN|Phần)\s+(THỨ\s+[A-ZĐÁÀẢÃẠĂẮẰẲẴẶÂẤẦẨẪẬÉÈẺẼẸÊẾỀỂỄỆÍÌỈĨỊÓÒỎÕỌÔỐỒỔỖỘƠỚỜỞỠỢÚÙỦŨỤƯỨỪỬỮỰÝỲỶỸỴ]+|[IVXLCDM]+)\b"

```
REGEX_CHAPTER   = r"^(CHƯƠNG|Chương)\s+([IVXLCDM]+|\d+)\b"

REGEX_SECTION   = r"^(MỤC|Mục)\s+(\d+|[IVXLCDM]+)\b"

REGEX_SUBSECT   = r"^(TIÊU MỤC|Tiểu mục)\s+(\d+)\b"

REGEX_ARTICLE   = r"^Điều\s+(\d+[a-zđ]?)\.\s*(.*)$"

REGEX_CLAUSE    = r"^(\d+)\.\s+(.*)$"

REGEX_POINT     = r"^([a-zđ])\)\s+(.*)$"

REGEX_DOC_NUM   = r"\b(\d+/\d{4}/[A-ZĐ0-9\-]+)\b"
```

3.2. Phân hệ 2: Mã hóa Đa biểu diễn và Lưu trữ Vector

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu cầu Chức năng
FR-IDX-01	Bắt buộc	Mã hóa Đồng thời Dense và Sparse: Sử dụng mô hình BAAI/bge-m3 để sinh đồng thời trong một lần suy luận gồm Dense Vector chuẩn hóa L2 1024 chiều phục vụ tìm kiếm ngữ nghĩa và Sparse Lexical Weights phục vụ khớp chính xác từ khóa, số hiệu, mức tiền phạt.
FR-IDX-02	Bắt buộc	Đánh chỉ mục Đa phương thức: Thiết lập chỉ mục HNSW

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu câu Chức năng
		với độ đo COSINE cho trường dense_vector và chỉ mục SPARSE_INVERTED_INDEX với độ đo Inner Product cho trường sparse_vector, đồng thời đánh chỉ mục vô hướng cho các trường lọc Metadata.
FR-IDX-03	Bắt buộc	Cập nhật Bất biến và Chống Trùng lặp: Mỗi chunk được cấp một khóa chính chunk_id sinh tự động bằng hàm băm SHA-256 từ tổ hợp doc_number, article_id và clause_id. Khi nạp lại cùng một văn bản, hệ thống thực hiện ghi đè mà không tạo bản ghi trùng lặp.
FR-IDX-04	Quan trọng	Quản lý Vòng đời Hiệu lực Văn bản: Hỗ trợ cập nhật nhanh trường trạng thái effective_status gồm active, amended, expired ở cấp độ toàn văn bản theo doc_number mà không cần tính toán lại vector embedding.

Đặc tả Schema Cơ sở Dữ liệu Vector

Tên Trường	Kiểu Dữ liệu	Kích thước và Tham số	M
chunk_id	VarChar PK	max_length = 64	K n b
doc_id	VarChar	max_length = 64	M h
doc_number	VarChar Indexed	max_length = 64	S n
doc_title	VarChar	max_length = 512	T b
doc_type	VarChar Indexed	max_length = 64	L L Q
issuing_body	VarChar	max_length = 128	C h
issued_year	Int16 Indexed	16-bit integer	N v m
effective_status	VarChar Indexed	max_length = 32	T a
chapter_id	VarChar	max_length = 64	S
article_id	VarChar Indexed	max_length = 32	Đ n

Tên Trường	Kiểu Dữ liệu	Kích thước và Tham số	M
clause_id	VarChar Indexed	max_length = 32	Đ n g
referenced_provisions	Array VarChar	max_capacity = 32	D h c
raw_content	VarChar	max_length = 16384	T c ở
dense_vector	FloatVector	dim = 1024	V si
sparse_vector	SparseFloatVector	Dynamic Sparse	V si

3.3. Phân hệ 3: Truy xuất Lai và Tái xếp hạng Ngữ nghĩa

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu câu Chức năng
FR-RET-01	Bắt buộc	Nhận diện Thực thể Pháp lý trong Câu hỏi: Phân tích câu hỏi trước khi truy vấn để phát hiện các thực thể định danh như Số hiệu văn bản, số Điều, số Khoản và tự động tạo biểu thức lọc hoặc tăng trọng số ưu tiên.

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu câu Chức năng
FR-RET-02	Bắt buộc	Bộ lọc Hiệu lực Mặc định: Mặc định mọi truy vấn tìm kiếm đều áp dụng điều kiện lọc effective_status != 'expired', trừ khi người dùng chủ động bật tùy chọn tra cứu văn bản hết hiệu lực.
FR-RET-03	Bắt buộc	Truy xuất Lai Song song: Thực thi đồng thời hai yêu cầu tìm kiếm trên trường dense_vector lấy Top-25 ứng viên và trên trường sparse_vector lấy Top-25 ứng viên.
FR-RET-04	Bắt buộc	Hợp nhất Thứ hạng bằng RRF: Kết quả từ hai nhánh tìm kiếm Dense và Sparse được hợp nhất bằng thuật toán RRF với hằng số làm mượt k = 60, chọn ra Top-25 chunk duy nhất có điểm cao nhất.
FR-RET-05	Bắt buộc	Tái xếp hạng bằng Mô hình Cross-Encoder: Tập 25 ứng viên sau bước RRF được ghép cặp trực tiếp với câu hỏi gốc và đưa qua mô hình BAAI/bge-reranker-v2-m3 để chấm điểm, chuẩn hóa qua

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu cầu Chức năng
		hàm Sigmoid về đoạn [0, 1] và giữ lại Top-5 chunk cao điểm nhất.
FR-RET-06	Bắt buộc	Công Kiểm soát Độ tin cậy: Kiểm tra điểm số sau chuẩn hóa của Top-5 chunk so với ngưỡng cấu hình RERANK_SCORE_THRESHOLD mặc định bằng 0.35. Nếu không có chunk nào đạt ngưỡng, hệ thống kích hoạt cờ abstained = True để từ chối trả lời an toàn.

3.4. Phân hệ 4: Sinh Câu trả lời Có Căn cứ và Kiểm soát Ảo giác

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu cầu Chức năng
FR-GEN-01	Bắt buộc	Ràng buộc Nguồn Tri thức Tuyệt đối: Mô hình LLM chỉ được phép sử dụng thông tin nằm trong các đoạn văn bản pháp luật được truyền vào khối ngữ cảnh. Nghiêm cấm tự bịa ra số hiệu văn bản, mức phạt tiền, thời hạn hành chính hoặc quyền nghĩa vụ pháp lý.

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu câu Chức năng
FR-GEN-02	Bắt buộc	Chuân hóa Định dạng Trích dẫn Bắt buộc: Mọi kết luận, con số hoặc quy định nêu trong câu trả lời phải đi kèm trích dẫn đầy đủ ngay trong câu theo cấu trúc: Căn cứ theo [Điểm ...], [Khoản ...], [Điều ...], [Tên và Số hiệu văn bản] [Nguồn i].
FR-GEN-03	Bắt buộc	Xử lý Từ chối Trả lời Chuẩn mực: Khi cờ abstained = True hoặc khi các điều khoản trong ngữ cảnh không chứa đủ thông tin, hệ thống phải trả về thông báo chuẩn nêu rõ chưa tìm thấy quy định trực tiếp trong kho dữ liệu hiện tại.
FR-GEN-04	Quan trọng	Cảnh báo Điêu khoản Dân chiếu Chéo Chưa Đầy đủ: Nếu điều khoản dùng để trả lời có chứa câu dẫn chiếu sang một Điều, Khoản hoặc văn bản khác không nằm trong danh sách ngữ cảnh hiện tại, câu trả lời phải đính kèm lưu ý rõ ràng cho người dùng.
FR-GEN-05	Bắt buộc	Câu hình Tham sô Suy luận Tất định: Các lệnh gọi tới LLM

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu câu Chức năng
		Server phải cô định bộ tham số sinh văn bản nhằm giảm thiểu tính ngẫu nhiên gồm temperature = 0.1, top_p = 0.90, repetition_penalty = 1.05, max_tokens = 1024.
FR-GEN-06	Bắt buộc	Phản hồi Dạng Luồng Thời gian thực: Hỗ trợ trả kết quả từng token ngay khi sinh thông qua giao thức SSE, đồng thời đính kèm toàn bộ mảng đối tượng trích dẫn gốc.

Mẫu System Prompt Chuẩn Kiểm soát Ảo giác Pháp lý

Bạn là Trợ lý Pháp lý AI chuyên nghiệp, hỗ trợ tra cứu và giải đáp Văn bản Quy phạm Pháp luật Việt Nam.

Nhiệm vụ của bạn là trả lời câu hỏi của người dùng DỰA TRÊN VÀ CHỈ DỰA TRÊN các đoạn trích văn bản pháp luật được cung cấp trong thẻ <legal_context> dưới đây.

QUY TẮC BẮT BUỘC TUÂN THỦ:

1. TRUNG THỰC TUYỆT ĐỐI VỚI NGỮ CẢNH: Chỉ sử dụng thông tin có trong <legal_context>. Tuyệt đối KHÔNG tự suy diễn, KHÔNG dùng kiến thức bên ngoài để tự thêm mức phạt, thời hạn, số Điều, số Khoản hoặc số hiệu văn bản không xuất hiện trong <legal_context>.

2. TRÍCH DẪN CĂN CỨ RÕ RÀNG: Mọi khẳng định pháp lý đưa ra phải nêu rõ căn cứ theo định dạng: "Căn cứ [Điểm ...], [Khoản ...], [Điều ...] của [Tên văn bản - Số hiệu] [Nguồn X]".

3. XỬ LÝ KHI THIẾU THÔNG TIN: Nếu các đoạn văn bản trong <legal_context> không chứa thông tin để trả lời chính xác câu hỏi, hãy trả lời rõ ràng: "Dữ liệu văn bản pháp luật hiện có trong hệ thống chưa quy định trực tiếp về vấn đề này."

4. CẢNH BÁO DẪN CHIẾU: Nếu điều khoản trong <legal_context> dẫn chiếu đến một Điều, Khoản hoặc văn bản khác không có mặt trong <legal_context>, hãy ghi chú rõ để người dùng tra cứu thêm điều khoản được dẫn chiếu đó.

5. VĂN PHONG: Trình bày bằng tiếng Việt chuẩn mực, khách quan, rõ ràng, ngắn gọn.

3.5. Phân hệ 5: Quản trị Hệ thống, Nhật ký Kiểm toán và Giám sát

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu cầu Chức năng
FR-ADM-01	Bắt buộc	Lưu Nhật ký Kiểm toán Truy vấn: Mọi yêu cầu hỏi đáp phải được ghi nhận vào cơ sở dữ liệu log nội bộ bao gồm request_id, timestamp, nội dung câu hỏi, danh sách chunk_id được truy xuất, điểm rerank_score tương ứng, câu trả lời sinh ra và thời gian xử lý từng khâu.
FR-ADM-02	Quan trọng	Cơ chế Thu thập Phản hồi Người dùng: Giao diện và API

Mã YC	Mức ưu tiên	Mô tả Chi tiết Yêu câu Chức năng
		hô trợ người dùng đánh giá chất lượng từng câu trả lời gắn liền với request_id để làm dữ liệu tinh chỉnh hệ thống.
FR-ADM-03	Bắt buộc	Kiêm tra Sức khỏe Dịch vụ Toàn trình: Cung cấp API kiểm tra trạng thái kết nối và sẵn sàng hoạt động của toàn bộ các thành phần phụ thuộc gồm Vector DB, Embedding Service, Reranker Service và LLM Inference Server.

4. ĐẶC TẢ GIAO DIỆN NGOÀI

4.1. Giao diện Người dùng

- UI-01 — Khung Hội thoại Tra cứu Pháp luật: Hỗ trợ nhập câu hỏi tiếng Việt tự nhiên, hiển thị trạng thái tiến trình xử lý và hiển thị văn bản trả lời theo thời gian thực.
- UI-02 — Thẻ Đối chiếu Trích dẫn Nguyên gốc: Ngay bên dưới mỗi câu trả lời, giao diện bắt buộc hiển thị danh sách các thẻ nguồn [Nguồn 1], [Nguồn 2]. Khi người dùng nhấp vào thẻ nguồn, giao diện mở rộng hiển thị đầy đủ Số hiệu văn bản, Tên văn bản, Chương, Điều, Khoản, Điểm số độ tin cậy và toàn bộ đoạn văn bản gốc.
- UI-03 — Bộ lọc Phạm vi Pháp lý: Cho phép người dùng tùy chọn giới hạn phạm vi tìm kiếm theo Loại văn bản, Năm ban hành, hoặc nhập Số hiệu văn bản cụ thể cần tra cứu.

4.2. Giao diện Lập trình Ứng dụng

Phương thức và Endpoint	Chức năng	Đầu vào	Đ
POST /api/v1/ingest	Tải lên và lập chỉ mục văn bản pháp luật mới vào hệ thống.	Multipart/form-data gồm tệp văn bản và JSON Metadata: doc_number, doc_type, issued_year, effective_status.	J K lu c
POST /api/v1/query	Thực thi truy vấn hỏi đáp pháp luật qua toàn bộ luồng RAG.	JSON chứa câu hỏi query, bộ lọc filters, cấu hình top_k, top_n, và cờ stream.	J S c
PATCH /api/v1/documents/{doc_id}/status	Cập nhật trạng thái hiệu lực của một văn bản pháp luật.	JSON chứa trường effective_status nhận giá trị active, amended hoặc expired.	J c th
GET /api/v1/health	Kiểm tra tình trạng hoạt động của các container dịch vụ.	Không yêu câu tham sô.	H c E E

Đặc tả JSON Contract cho API Truy vấn

```
{
 "request": {
  "query": "Đi xe không đội mũ bảo hiểm bị phạt bao nhiêu?",
  "filters": {
   "doc_types": ["Nghị định"],
```

```
    "only_active": true
  },
  "top_k_retrieval": 25,
  "top_n_rerank": 5,
  "score_threshold": 0.35,
  "stream": false
},
"response": {
  "request_id": "req_9021a8f4c12",
  "abstained": false,
  "answer": "Phạt tiền từ 400.000 đồng đến 600.000 đồng đối với người điều khiển xe mô tô, xe gắn máy không đội mũ bảo hiểm cho người đi mô tô, xe gắn máy hoặc đội mũ bảo hiểm không cài quai đúng quy cách khi tham gia giao thông đường bộ. Căn cứ pháp lý: Điểm i Khoản 2 Điều 6 Nghị định 100/2019/NĐ-CP [Nguồn 1].",
  "citations": [
    {
      "source_index": 1,
      "chunk_id": "sha256_8d4f2a901bc3",
```

```
      "doc_number": "100/2019/NĐ-CP",

      "doc_title": "Nghị định quy định xử phạt vi phạm hành chính trong lĩnh vực giao thông đường bộ và đường sắt",

      "chapter_id": "Chương II",

      "article_id": "Điều 6",

      "clause_id": "Khoản 2",

      "effective_status": "active",

      "rerank_score": 0.941,

      "raw_excerpt": "[Văn bản: Nghị định 100/2019/NĐ-CP] [Chương II] [Điều 6: Xử phạt người điều khiển xe mô tô, xe gắn máy...] Khoản 2: Phạt tiền từ 400.000 đồng đến 600.000 đồng đối với người điều khiển xe thực hiện một trong các hành vi vi phạm sau đây: ... i) Không đội mũ bảo hiểm cho người đi mô tô, xe gắn máy hoặc đội mũ bảo hiểm cho người đi mô tô, xe gắn máy không cài quai đúng quy cách khi tham gia giao thông trên đường bộ..."

    }

  ],

  "metrics": {

    "retrieval_latency_ms": 78,

    "rerank_latency_ms": 195,

    "generation_latency_ms": 2410,
```

```
    "total_latency_ms": 2683
  }
 }
}
```


4.3. Giao diện Hạ tầng Container và Truyền thông Kiến trúc Lai

Hệ thống hỗ trợ cơ chế giao tiếp kết hợp giữa mạng nội bộ Docker Bridge Network `legal_rag_net` và các giao diện kết nối dịch vụ Đám mây:

- `vector-db` (Cổng 19530 / 6333): Cung cấp giao thức gRPC và REST tốc độ cao cho các thao tác truy vấn và nạp vector.
- `embedding-reranker-service` (Cổng 8001): Dịch vụ nạp sẵn mô hình BAAI/bge-m3 và BAAI/bge-reranker-v2-m3, xử lý theo lô.
- `llm-inference-server` (Cổng 8000 / 11434): Phục vụ mô hình Qwen2.5-Instruct thông qua giao diện tương thích chuẩn OpenAI API.
- `legal-rag-backend` (Cổng 8080): Điều phối luồng nghiệp vụ RAG, kết nối tới Vector DB, Embedding/Reranker Service và LLM Server.
- `legal-rag-ui` (Cổng 8501): Giao diện người dùng tương tác trực tiếp với Backend qua REST và SSE.
- `cloud-vector-db-interface`: Giao tiếp với Qdrant Cloud / Zilliz Cloud qua giao thức REST API hoặc gRPC bảo mật bằng API Key.
- `cloud-relational-db-interface`: Kết nối đến Neon.tech / Supabase PostgreSQL qua chuỗi kết nối mã hóa SSL/TLS.
- `local-ollama-interface`: Gửi truy vấn trực tiếp đến máy chủ Ollama chạy tại local qua cổng localhost:11434, đảm bảo dữ liệu suy luận không rời khỏi máy người dùng.

5. YÊU CÂU PHI CHỨC NĂNG

5.1. Yêu cầu về Hiệu năng và Độ trễ

Mã YC	Chỉ tiêu Kỹ thuật	Mức Cam kết	Đ
NFR-PERF-01	Độ trễ Truy xuất Lai	<= 150 ms (p95)	T S 1(
NFR-PERF-02	Độ trễ Tái xếp hạng	<= 500 ms (p95)	C c re
NFR-PERF-03	Thời gian Phản hồi Token Đầu tiên	<= 2.500 ms (p95)	Đ 2
NFR-PERF-04	Tổng Thời gian Sinh Câu trả lời	<= 8.5 giây (p95)	C đ ti
NFR-PERF-05	Thông lượng Lập chỉ mục Văn bản	>= 100 trang / phút	B si s(

5.2. Yêu cầu về Chất lượng Truy xuất và Độ chính xác Pháp lý

Mã YC	Chỉ số Đánh giá	Ngưỡng Đạt Chuẩn	P n
NFR-QUAL-01	Recall@25	>= 92%	T k T b

Mã YC	Chỉ số Đánh giá	Ngưỡng Đạt Chuẩn	P n
NFR-QUAL-02	Hit Rate@5	>= 85%	T k T k
NFR-QUAL-03	MRR@5	>= 0.75	Đ k T R
NFR-QUAL-04	Citation Precision	100%	M S tr tr x
NFR-QUAL-05	Faithfulness	>= 95%	M m tr g
NFR-QUAL-06	Abstention Accuracy	>= 90%	K p th c

5.3. Yêu cầu về Bảo mật và Tính Độc lập Vận hành

- NFR-SEC-01 — Vận hành Độc lập Không Kết nối Ngoại mạng: Toàn bộ trọng số mô hình được tải trước và ánh xạ từ ổ đĩa cục bộ vào Container. Hệ thống suy luận hoạt động bình thường khi ngắt kết nối Internet.

- NFR-SEC-02 — Chống Tấn công Prompt Injection: Đầu vào của người dùng phải được bao bọc tách biệt trong thẻ phân cách dữ liệu và kiểm tra lọc các mẫu câu lệnh cố tình ghi đè System Prompt.
- NFR-SEC-03 — Xác thực Dịch vụ Đám mây và Cách ly Tri thức: Toàn bộ khóa truy cập API Key kết nối Cloud Vector DB và chuỗi kết nối PostgreSQL Cloud phải được mã hóa, lưu trữ độc lập trong tệp cấu hình môi trường. Mô hình ngôn ngữ lớn Ollama bắt buộc vận hành cục bộ trên máy người dùng, đảm bảo tuyệt đối không rò rỉ dữ liệu truy vấn và ngữ cảnh pháp lý ra bên ngoài.

5.4. Yêu cầu về Khả năng Bảo trì và Mở rộng

- NFR-MNT-01 — Cấu hình Hóa Tham số và Khóa API: Mọi tham số quan trọng gồm tên model, địa chỉ endpoint Ollama local, địa chỉ Cloud Vector DB, chuỗi kết nối PostgreSQL, khóa API Key, kích thước chunk, giá trị top_k, top_n, ngưỡng RERANK_SCORE_THRESHOLD và System Prompt được quản lý tập trung qua tệp cấu hình `.env` hoặc `config.yaml`.
- NFR-MNT-02 — Khởi tạo Toàn hệ thống Một chạm: Toàn bộ hệ thống khởi chạy đồng bộ và tự động thiết lập kết nối thông qua lệnh chuẩn `docker compose up -d`.

6. TIÊU CHÍ KIỂM THỬ VÀ NGHIỆM THU HỆ THỐNG

Mã Kịch bản	Tên Nhóm Kiểm thử	Mô tả Kịch bản và Dữ liệu Đầu vào	T
SUITE-A	Tra cứu Đích danh Điều khoản và Số hiệu	Bộ câu hỏi chỉ định rõ số Điều, Khoản và Số hiệu văn bản.	N fi k tr k

Mã Kịch bản	Tên Nhóm Kiểm thử	Mô tả Kịch bản và Dữ liệu Đầu vào	T
SUITE-B	Hỏi đáp Tình huống Ngôn ngữ Đời thường	Bộ câu hỏi sử dụng từ ngữ thông dụng, không chứa thuật ngữ luật học chính xác.	N R q tr K
SUITE-C	Tra cứu Khung Định lượng và Bảng biểu	Các câu hỏi liên quan đến mức phạt tiền, tỷ lệ phần trăm, thời hạn hoặc dữ liệu nằm trong bảng phụ lục.	C th lỗ li
SUITE-D	Kiểm thử Văn bản Sửa đổi và Hiệu lực	Các câu hỏi về điều khoản đã có văn bản sửa đổi, bổ sung hoặc văn bản đã hết hiệu lực.	H b ư th lụ
SUITE-E	Kiểm thử Chống Ảo giác Ngoài Phạm vi	Các câu hỏi về lĩnh vực pháp luật chưa được nạp vào cơ sở dữ liệu hoặc câu hỏi gài bẫy chứa thông tin sai lệch.	H R c kh b